Predicción del caudal medio diario en cuencas de Colombia con una red LSTM regional

Santiago Palacios Loaiza, Diego Leonardo Barón Espitia, Andrés Felipe Mosquera Hernández y Juan Sebastián Rodríguez Avella

I. Descripción del contexto y planteamiento del problema

COLOMBIA depende del agua de manera estructural: cerca del 70 % de su producción eléctrica proviene de centrales hidráulicas en un año. Esta dependencia se agrava por una fuerte asimetría territorial: el área Magdalena-Cauca concentra el 74 % de la población y el 80 % del PIB, pero registra la menor oferta hídrica del país [1]. El país ha sufrido ambos extremos del régimen hidrológico: Bogotá enfrentó su primer racionamiento en cuatro décadas durante El Niño de 2024, y la ola invernal de La Niña 2010-2011 afectó a 5,2 millones de personas y costó cerca del 2 % del PIB [2]. En ambos casos la variable determinante es el caudal medio diario en las cuencas hídricas, y de él dependen decisiones como la operación de embalses, el despacho energético y las alertas de creciente. Además, el IDEAM, citando a la Organización Meteorológica Mundial (OMM), informó recientemente que la probabilidad de que el fenómeno de El Niño persista hasta febrero de 2027 es de casi 100 %, y estimó en 75 % la probabilidad de que sea el más fuerte del que se tenga registro [3].

La recolección y estandarización de información sobre fuentes hidrológicas suele ser retadora por el carácter diverso y cambiante de la naturaleza que además obedece a condiciones regionales. Los datasets de CAMELS (Catchment Attributes and Meteorology for Large-sample Studies) buscan proponer un marco de trabajo para la representación de cuencas hidrográficas. El recientemente creado CAMELS-COL [4] habilita la aproximación a estudios de caudal mediante el uso de machine learning en Colombia. El desempeño de modelos regionales que agrupan las cuencas de todo el territorio no ha sido evaluado en el país y ofrece una oportunidad interesante por la variedad de regiones geográficas. Por ejemplo, un mismo modelo debe representar tanto la región andina, con lluvias constantes entre valles y cordilleras, como la Orinoquia, donde se presentan biomas de sabanas inundables con temporadas de lluvias y sequías bien delimitadas.

Esta ausencia es relevante porque la evidencia disponible proviene de contextos que difieren del colombiano en dos aspectos determinantes: los regímenes hidrológicos estudiados son templados o dominados por nieve, y los atributos de cuenca que usan estos modelos (como la fracción de precipitación en forma de nieve) carecen de equivalente en el trópico [5]. Adicionalmente, el desempeño de estos modelos depende del número de cuencas de entrenamiento [5], [6], condición que en Colombia varía en un orden de magnitud entre regiones. Este proyecto aporta una primera evaluación de un modelo LSTM regional de caudal diario para Colombia, incluida su capacidad de generalizar a cuencas no vistas. Desde el punto de vista de negocio, el proyecto busca apoyar la operación de embalses y el despacho energético con estimaciones diarias de caudal, y las alertas de creciente en cuencas sin estaciones de medición.

Universidad de los Andes, Bogotá, Colombia (e-mail: s.palaciosl@uniandes.edu.co; d.barone@uniandes.edu.co; a.mosquerah2@uniandes.edu.co; js.rodrigueza1@uniandes.edu.co).

Tabla I
Definición de términos

Término	Definición
Caudal medio diario	Promedio diario del volumen de agua que atraviesa una sección del río por unidad de tiempo.
Cuenca hidrográfica	Territorio cuyas aguas drenan hacia un mismo punto de salida.
Dinámicas hidroclimáticas	Respuesta del caudal de una cuenca a las condiciones del clima en el tiempo.
Datos hidrometeorológicos	Mediciones de variables hidrológicas y meteorológicas.
Regiones hidrológicas	Las cinco áreas hidrográficas del país: Caribe, Magdalena-Cauca, Orinoco, Amazonas y Pacífico.
CAMELS-COL	Versión colombiana de CAMELS, con datos de caudal, meteorología y atributos de cuencas del país.
Modelo regional	Único modelo entrenado con los datos de varias cuencas a la vez.
NSE (eficiencia de Nash-Sutcliffe)	Mide cuánto mejor predice el modelo el caudal que su promedio observado.
KGE (eficiencia de Kling-Gupta)	Mide la coincidencia entre caudal simulado y observado en correlación, variabilidad y promedio.

II. Objetivos del proyecto

Los términos usados en los objetivos se definen en la Tabla I.

A. Objetivo general

Desarrollar un modelo predictivo de caudal medio diario para cuencas hidrográficas de Colombia mediante una arquitectura de red neuronal LSTM, que capture las dinámicas hidroclimáticas del país a partir de variables meteorológicas y características físicas de cuenca.

B. Objetivos específicos

1) Construir un pipeline de limpieza y estructuración de datos hidrometeorológicos y de atributos de cuenca a nivel nacional, cubriendo las cinco regiones hidrológicas del país, usando como principal insumo CAMELS-COL. Meta: las 346 cuencas de CAMELS-COL quedan procesadas y listas para el modelo.
2) Entrenar un modelo LSTM regional que reciba series meteorológicas diarias junto con atributos estáticos de cuenca, y prediga caudal medio diario, evaluado con métricas hidrológicas estándar (NSE, KGE) además de RMSE/MAE. Meta: NSE y KGE medianos de al menos 0,70 en el periodo de prueba.
3) Evaluar la capacidad de generalización del modelo a cuencas no vistas (ungauged basins), como medida de su aplicabilidad a zonas con monitoreo limitado. Meta: NSE mediano de al menos 0,50 en las cuencas no vistas.

III. Revisión del estado del arte y bibliografía

El trabajo reciente en modelado lluvia-escorrentía con aprendizaje profundo puede organizarse según el tipo de inferencia que realiza. El modelado lluvia-escorrentía estima el caudal que genera una cuenca a partir de la precipitación. Un primer grupo entrena y evalúa sobre cuencas aforadas, ya sea mediante modelos por cuenca que hibridan un modelo conceptual (GR4J) con redes neuronales bajo regresión cuantílica [7], o comparando arquitecturas para la detección de eventos extremos como inundaciones o sequías [8]. Una cuenca aforada es la que tiene una estación de aforo, es decir, una estación que mide su caudal. Un modelo conceptual representa la cuenca mediante depósitos de agua y ecuaciones simplificadas. GR4J (*modèle du Génie Rural à 4 paramètres Journalier*) es un modelo conceptual diario de cuatro parámetros. La regresión cuantílica estima cuantiles de la distribución de la variable objetivo en lugar de su media. Un segundo grupo aborda la predicción en cuencas no aforadas (PUB, por *Prediction in Ungauged Basins*), entrenando modelos regionales sobre cuencas instrumentadas y transfiriéndolos a cuencas sin registro [6], [9], o incorporando caudal observado de cuencas donantes vecinas [10]. Una cuenca no aforada es la que no tiene estación de aforo. Una cuenca donante es una cuenca aforada cuyo caudal se usa para estimar el de una cuenca no aforada. Un tercer grupo examina decisiones de diseño experimental: si conviene especializar el modelo por clases de cuencas hidrológicamente similares frente a un modelo regional único [5], y cuánta historia se requiere para entrenar [11]. En cuanto a arquitecturas, la LSTM se mantiene como referencia dominante, acompañada de variantes con atención, híbridos con modelos conceptuales, Transformers temporales y mezclas de expertos. Los estudios se concentran en Estados Unidos, Canadá, Australia e India, con muestras de 14 a 1.374 cuencas, sin trabajos comparables para Colombia.

Algunos ejemplos de estudios previos son:

- **Transfer learning using the global Caravan dataset for developing a local river streamflow prediction model [12]:** Este estudio utiliza información global para entrenar y posteriormente aplica transfer learning con los datos de la cuenca del río Uba en Kazajistán. Caravan, el conjunto de datos global que usa este estudio, reúne datos hidrometeorológicos de cuencas de varios países. Se probaron diferentes arquitecturas del LSTM de la librería de NeuralHydrology y se concluyó que hay beneficios en el preentrenamiento con datos globales de manera limitada. NeuralHydrology es una librería de Python para modelos de deep learning en hidrología.
- **Deep learning approaches for streamflow flash drought prediction across the contiguous United States [8]:** Este estudio compara tres arquitecturas: LSTM, LSTM+atributos estáticos y Temporal Fusion Transformer en una tarea no solo de predicción de caudal sino también de detección de eventos como problema de clasificación. El Temporal Fusion Transformer es una variante de Transformer para pronóstico de series de tiempo. Los resultados concluyen que la inclusión de atributos estáticos disminuye en gran medida los falsos positivos de la tarea de clasificación.
- **How much historical data do we need? The role of data recency and training period length in LSTM-based rainfall-runoff modeling [11]:** Este estudio se enfoca puramente en la experimentación: ¿cuántos años incluir en el entrenamiento y cuándo fueron esos años? ¿Qué tan cercanos son a la fecha de predicción? Los resultados concluyen que los datos muy lejanos en tiempo aportan muy poco valor, mientras que los más recientes tienen un mejor aporte al entrenamiento. Además, concluyen que la inclusión de demasiados años (+40) tiende a generar un techo en los resultados que se logra corregir con la inclusión de datos de más cuencas hidrográficas.

IV. Metodología propuesta

Esta investigación es de tipo cuantitativo y experimental: a partir de las series hidrometeorológicas diarias y los atributos de cuenca de CAMELS-COL se entrena un modelo de aprendizaje profundo, y su desempeño se mide con métricas hidrológicas estándar (NSE, KGE) y de error (RMSE, MAE) en experimentos controlados. La metodología se organiza en tres etapas, una por cada objetivo específico: la construcción del pipeline de limpieza y estructuración de los datos (Sección IV-A), el entrenamiento del modelo LSTM regional (Sección IV-B) y la evaluación de su capacidad de generalización a cuencas no vistas (Sección IV-C).

Los modelos se entrenarán en un computador portátil con GPU NVIDIA GeForce RTX 3050 de 6 GB, procesador Intel Core i5-12450H y 38 GB de RAM, y en Google Colab como alternativa. En una prueba en esta GPU, cada actualización de parámetros con la configuración de la Sección IV-B tarda 21,5 ms y usa 0,3 GB de memoria. Con unos 3 millones de muestras de entrenamiento, cada época toma cerca de 17 minutos, y un entrenamiento de hasta 30 épocas [10], [11], unas 8,5 horas. Estos recursos justifican tres decisiones: partir de una configuración validada en la literatura y ajustar solo el tamaño de la capa oculta, en lugar de probar muchas configuraciones; usar lotes de 64 secuencias, que caben con holgura en la memoria de la GPU; y evaluar la generalización con 5

particiones, que requieren cinco entrenamientos, en lugar de dejar fuera cada sistema de ríos por separado (Sección IV-C), que requeriría 44.

A. Pipeline de limpieza y estructuración de datos

El insumo son las 346 cuencas de CAMELS-COL [4], con series diarias de 1981 a 2022 de precipitación, evapotranspiración potencial, temperatura mínima y máxima (forzantes) y caudal (objetivo). Los forzantes son las variables meteorológicas de entrada del modelo. La evapotranspiración potencial es la pérdida máxima de agua del suelo y la vegetación por evaporación y transpiración. Como los días sin registro no aparecen como filas en los archivos, cada serie se reindexa a un calendario diario continuo. Los huecos de los forzantes se completan por interpolación lineal, como en [7], [8]; el caudal faltante no se imputa, sino que se excluye del cálculo de la pérdida y de las métricas, siguiendo a [9], para no entrenar sobre valores sintéticos. No se descartan cuencas por datos faltantes: el umbral de 5 % usado en [11] eliminaría cerca de la mitad del conjunto, y los autores de CAMELS-COL ya exigieron un 70 % de disponibilidad. El caudal se convierte de m^3/s a mm/día dividiendo por el área de la cuenca, para que sea comparable entre cuencas de tamaños muy distintos [6], [10].

De los 71 atributos estáticos se conservan los fisiográficos, climáticos, de cobertura, geología, suelos y capacidad de uso, y se excluyen las 11 firmas hidrológicas (p. ej. `q_mean`, `baseflow_index`): se calculan a partir del caudal observado, por lo que no existen en una cuenca no aforada y su uso causaría fuga de información. Las firmas hidrológicas son índices que resumen el comportamiento del caudal observado de una cuenca. Los índices climáticos se recalculan con los forzantes del periodo de entrenamiento, para que no incorporen información de los años de prueba. Forzantes, atributos y caudal se estandarizan con z-score usando solo estadísticos de las cuencas y del periodo de entrenamiento [6], [10]. La partición temporal reserva los años más recientes para la prueba, dado que los datos recientes son los más informativos [11]: entrenamiento 1981–2010, validación 2011–2015 y prueba 2016–2022; 252 de las 346 cuencas tienen registros en el periodo de prueba. Finalmente, las muestras se organizan como ventanas de 365 días de forzantes junto con el vector de atributos, longitud que obtuvo el mejor desempeño en [6] y es la usada en [10], [12].

B. Entrenamiento del modelo LSTM regional

Se entrena un único LSTM regional con las cuencas de todas las regiones, en lugar de un modelo por cuenca o por grupo de cuencas: un modelo compartido generaliza mejor a cuencas no vistas [6], y la especialización por clases pierde frente al modelo regional cuando cada clase tiene pocas cuencas [5], como ocurriría con Amazonas (22) o Pacífico (32). En cada paso de tiempo el modelo recibe los cuatro forzantes concatenados con los atributos estáticos [6], [10] y predice el caudal del último día de la ventana. No se usa caudal rezagado como entrada, a diferencia de [8], [9], porque ese dato no existe en cuencas no aforadas. El caudal rezagado es el caudal observado en días anteriores al que se quiere predecir.

Como configuración inicial se adopta la reportada en [10], [12]: una capa LSTM de 256 unidades, dropout de 0,4, optimizador Adam con tasa de aprendizaje de 5×10^{-4} y lotes de 64 secuencias. La función de pérdida es el NSE^* [5], [11]. El NSE^* es un NSE que normaliza el error de cada cuenca por la desviación estándar de su caudal. Esa desviación estándar se calcula solo con el periodo de entrenamiento. Así, las cuencas grandes no dominan el entrenamiento. El tamaño de la capa oculta se ajusta con el periodo de validación de las 216 cuencas que nunca se retienen en la Sección IV-C, ya que la complejidad del LSTM debe corresponder al número de cuencas de entrenamiento [5], y se aplica parada temprana sobre ese mismo periodo [11]. La implementación usa la librería NeuralHydrology, empleada en [9], [11], [12].

El modelo se evalúa en el periodo de prueba con NSE, KGE, RMSE y MAE, calculados por cuenca tras desnormalizar las predicciones [6] y resumidos con la mediana entre cuencas [10], [11].

C. Evaluación de la generalización a cuencas no vistas

La generalización espacial se evalúa con validación cruzada de 5 particiones. En CAMELS-COL, 324 de las 346 cuencas están anidadas, es decir, tienen otra cuenca aguas arriba o aguas abajo, por lo que retener una cuenca y entrenar con sus cuencas anidadas filtraría su caudal al modelo. Por eso las particiones se forman con sistemas de ríos completos, es decir, grupos de cuencas conectadas por anidamiento: los dos sistemas más grandes, con 176 cuencas de Magdalena-Cauca y 40 del Orinoco, permanecen siempre en el entrenamiento, y los 44 sistemas restantes, con 130 cuencas, se reparten en cinco particiones de 26 cuencas. En cada iteración el modelo se entrena, con la configuración de la Sección IV-B, sobre las 320 cuencas restantes y se evalúa sobre las retenidas, que funcionan como cuencas no aforadas: el modelo nunca vio su caudal ni el de ninguna cuenca conectada con ellas, y solo recibe sus forzantes y atributos estáticos. En cada partición, la estandarización y la parada temprana usan solo las cuencas de entrenamiento de esa partición. Así, las 130 cuencas se evalúan sin fuga de información, en lugar de un único subconjunto retenido como en [9]–[11] o de solo tres cuencas como en [6]; esta evaluación cubre todas las cuencas del Caribe, el Pacífico y el Amazonas, pero solo 17 del Orinoco y 6 de Magdalena-Cauca. Como el modelo no vio las cuencas retenidas en ningún año, se evalúan sobre todo su registro [6], [10], con las mismas métricas de la Sección IV-B; su desempeño es la medida de la aplicabilidad del modelo a zonas con monitoreo limitado.

D. Resultados esperados

Se espera obtener: (i) las 346 cuencas de CAMELS-COL procesadas y listas para el modelo; (ii) un modelo LSTM regional con NSE y KGE medianos de al menos 0,70 en el periodo de prueba; y (iii) un NSE mediano de al menos 0,50 en las cuencas no vistas.

V. Descripción inicial de los datos

Los datos utilizados provienen de CAMELS-COL [4], un conjunto de datos hidrometeorológicos de gran escala para Colombia, disponible públicamente en Zenodo (DOI: 10.5281/zenodo.18794895). CAMELS-COL sigue el marco estandarizado de las iniciativas CAMELS desarrolladas previamente para Estados Unidos, Chile y Brasil, lo que garantiza consistencia metodológica con datasets hidrológicos globales.

El conjunto de datos combina dos tipos de información complementaria. Por un lado, **series temporales diarias** (1981-2022) para 346 estaciones de aforo del IDEAM, distribuidas en las cinco regiones hidrológicas del país (Magdalena: 182 estaciones, Orinoco: 57, Caribe: 53, Pacífico: 32, Amazonas: 22). Estas series incluyen caudal medio diario (variable objetivo del modelo), precipitación (CHIRPS), evapotranspiración potencial y temperatura máxima/media/mínima (MSWX). CHIRPS (*Climate Hazards Group InfraRed Precipitation with Station data*) es un producto de precipitación estimada con satélites y estaciones. MSWX (*Multi-Source Weather*) es un producto global de variables meteorológicas construido a partir de varias fuentes. Por otro lado, el dataset provee **atributos estáticos por cuenca**, derivados principalmente de fuentes gubernamentales oficiales (IDEAM, IGAC, Servicio Geológico Colombiano): características fisiográficas, índices climáticos, firmas hidrológicas, cobertura del suelo, geología y propiedades edáficas. El IGAC (Instituto Geográfico Agustín Codazzi) es la entidad oficial de cartografía de Colombia. Las características fisiográficas describen la forma y el relieve de la cuenca. Los índices climáticos son indicadores que resumen el clima de una cuenca. La cobertura del suelo es el tipo de superficie que cubre el terreno. Las propiedades edáficas son las características del suelo.

En términos de volumen, se trabaja con más de 40 años de registros diarios multiplicados por 346 estaciones, además de más de 70 atributos estáticos por cuenca. En cuanto a calidad, los autores del dataset ya aplicaron un filtro de al menos 70 % de disponibilidad de datos por estación al seleccionar las 346 de un total de 921 estaciones originales del IDEAM, lo que da una base razonablemente confiable, aunque persisten huecos y banderas de control de calidad dentro de las series individuales que deben revisarse antes del modelado. Las banderas de control de calidad son marcas que indican la confiabilidad de cada dato.

A. Desafíos anticipados en la preparación de los datos

- **Desbalance regional:** la concentración de estaciones en la región Magdalena (53 % del total) frente a la escasez en Amazonas y Pacífico puede sesgar el aprendizaje del modelo hacia los patrones hidroclimáticos de esa región.
- **Datos faltantes:** las series de caudal presentan huecos que requieren una estrategia explícita de imputación o exclusión antes de alimentar el modelo secuencial.
- **Riesgo de fuga de información:** varios atributos estáticos (ej. `q_mean`, `baseflow_index`) se calculan directamente a partir del historial de caudal, por lo que su uso como variable de entrada exige cuidado en el diseño del split de entrenamiento/prueba para evitar contaminar la evaluación.
- **Incertidumbre en la fuente satelital de precipitación:** el propio estudio de origen reporta posible subestimación de precipitación por parte de CHIRPS en ciertas regiones, lo que puede afectar la relación precipitación-caudal aprendida por el modelo.

Referencias

[1] IDEAM, *Estudio Nacional del Agua 2022*. Bogotá, Colombia: Instituto de Hidrología, Meteorología y Estudios Ambientales, 2023. [En línea]. Disponible: https://www.ideam.gov.co/sala-de-prensa/informes/publicacion-jue-23032023-1200

[2] CEPAL y BID, *Valoración de daños y pérdidas: Ola invernal en Colombia, 2010–2011*. Bogotá, Colombia: Naciones Unidas, 2012, LC/BOG/L.23. [En línea]. Disponible: https://hdl.handle.net/11362/37958

[3] IDEAM, "El Niño se fortalece: aumenta a 75 % la probabilidad de que sea el más fuerte de la historia," Comunicado Especial No. 100, Bogotá, Colombia, 10 sep. 2026. [En línea]. Disponible: https://www.ideam.gov.co/file-download/download/public/22765

[4] D. A. Jimenez *et al.*, "CAMELS-COL: A large-sample hydrometeorological dataset for Colombia," Zenodo, 2026, conjunto de datos, doi: 10.5281/zenodo.18794895.

[5] M. He *et al.*, "Streamflow prediction in ungauged catchments through use of catchment classification and deep learning," *Journal of Hydrology*, vol. 639, art. 131638, 2024, doi: 10.1016/j.jhydrol.2024.131638.

[6] Y.-C. Chao *et al.*, "A Mixture-of-Experts deep learning architecture for daily streamflow prediction across the Sierra Nevada in California," *Hydrology Research*, art. 100039, 2026, doi: 10.1016/j.hydrch.2026.100039.

[7] A. Kapoor y R. Chandra, "QDeepGR4J: Quantile-based ensemble of deep learning and GR4J hybrid rainfall-runoff models for extreme flow prediction with uncertainty quantification," *Journal of Hydrology*, vol. 664, art. 134434, 2026, doi: 10.1016/j.jhydrol.2025.134434.

[8] S. Bakar, H. H. Nguyen, H. Kim y V. Laskhmi, "Deep learning approaches for streamflow flash drought prediction across the contiguous United States," *Journal of Hydrology*, vol. 677, art. 135956, 2026, doi: 10.1016/j.jhydrol.2026.135956.

[9] S. Barbhuiya y V. Gupta, "From gauged to ungauged: Large-scale deep learning rainfall-runoff modelling for reliable streamflow estimation in India's diverse basins," *Environmental Modelling & Software*, vol. 194, art. 106696, 2025, doi: 10.1016/j.envsoft.2025.106696.

[10] S. Wi, R. Gupta y S. Steinschneider, "Pooling local climate and donor gauges with deep learning for improved reconstructions of streamflow in ungauged and partially gauged basins," *Journal of Hydrology*, vol. 661, art. 133764, 2025, doi: 10.1016/j.jhydrol.2025.133764.

[11] Q. Yu y B. Tolson, "How much historical data do we need? The role of data recency and training period length in LSTM-based rainfall-runoff modeling," *Journal of Hydrology*, vol. 668, art. 135046, 2026, doi: 10.1016/j.jhydrol.2026.135046.

[12] A. Alzhanov, A. Nugumanova y V. Moreido, "Transfer learning using the global Caravan dataset for developing a local river streamflow prediction model," *Environmental Modelling & Software*, vol. 194, art. 106691, 2025, doi: 10.1016/j.envsoft.2025.106691.